

# TensorFlow Basic

Youngjae Yu

Aug 2, 2017

<https://github.com/yj-yu/tensorflow-basic>

<https://yj-yu.github.io/tensorflow-basic>



SEOUL NATIONAL UNIV.  
**VISION & LEARNING**

# About

- TensorFlow Basic - Op, Graph, Session, Feed 등
- Logistic Regression using TensorFlow
- `tf.flags`, Tensorboard 등 Minor tips
- Variable Saving, Restoring

# TensorFlow Basic

# Install anaconda

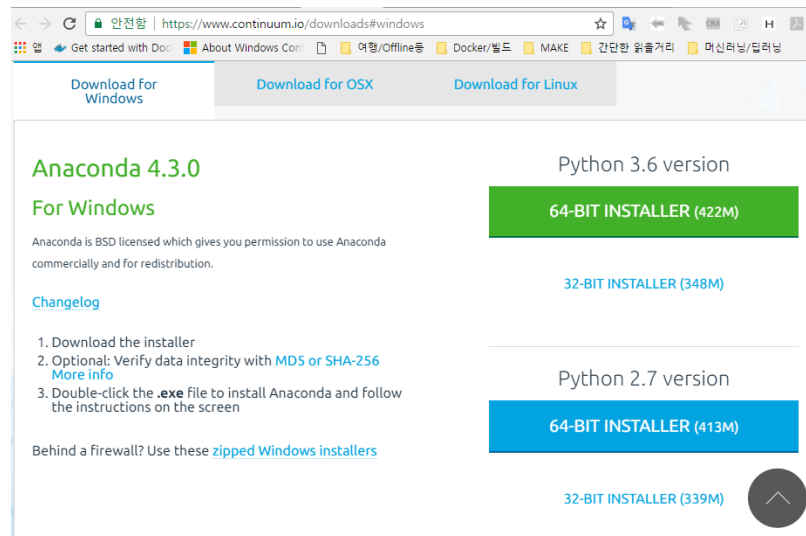
Install instruction for windows OS

[https://www.tensorflow.org/install/install\\_windows](https://www.tensorflow.org/install/install_windows)

Anaconda에 있는 배포판에 numpy 등 기본 라이브러리를 기본적으로 포함

아래 링크에서 Python 3.x 버전으로 설치를 해주세요.

<https://www.continuum.io/downloads#windows>



# Install anaconda

Windows 키를 누른뒤에 anaconda prompt 입력하면 console이 뜹니다.

conda 라는 명령어로 여러 개의 가상환경을 만들 수 있습니다.

```
conda create --name tf python=3.6
```

```
#tf라는 환경이 만들어졌는지 확인  
conda info --envs
```

# Install anaconda

자 이제 기본 실습환경 세팅을 위해 tf라는 가상 환경으로 들어갑니다.

```
activate tf
#만약 비활성화하고 싶다면 deactivate tf를 치세요.

#기본 라이브러리 확인
conda list
```

pip가 보이시죠? 이제 pip를 통해 tensorflow 및 실습 환경을 위한 라이브러리를 추가할 것입니다. 다음 명령어들을 입력하여 자동으로 tensorflow 최신 배포판을 설치합니다.

```
pip install ipython
pip install jupyter
pip install tensorflow
```

# Install configuration

```
git clone https://github.com/yj-yu/tensorflow-basic.git
cd tensorflow-basic
ls
```

code(<https://github.com/yj-yu/tensorflow-basic>)

```
./code
├── train.py
├── train_quiz1.py
├── train_quiz2.py
└── eval.py
```

- `train.py` : basic regression model code
- `train_quiz1.py` : quiz1 정답을 포함
- `train_quiz2.py` : quiz2 정답을 포함
- `eval.py` : quiz3 정답을 포함

# Tensor

## 데이터 저장의 기본 단위

```
import tensorflow as tf
a = tf.constant(1.0, dtype=tf.float32) # 1.0 의 값을 갖는 1차원 Tensor 생성
b = tf.constant(1.0, shape=[3,4]) # 1.0 의 값을 갖는 3x4 2차원 Tensor 생성
c = tf.constant(1.0, shape=[3,4,5]) # 1.0 의 값을 갖는 3x4x5 3차원 Tensor 생성
d = tf.random_normal(shape=[3,4,5]) # Gaussian Distribution 에서 3x4x5 Tensor를 Sampling

print (c)
```

```
<tf.Tensor 'Const_24:0' shape=(3, 4, 5) dtype=float32>
```



# TensorFlow Basic

## TensorFlow Programming의 개념

1. `tf.Placeholder` 또는 Input Tensor 를 정의하여 Input **Node**를 구성한다
2. Input Node에서 부터 Output Node까지 이어지는 관계를 정의하여 **Graph**를 그린다
3. **Session**을 이용하여 Input Node(`tf.Placeholder`)에 값을 주입(feeding) 하고, **Graph**를 **Run** 시킨다

# TensorFlow Basic

1과 2를 더하여 3을 출력하는 프로그램을 작성

**Tensor**들로 **Input Node**를 구성한다

```
import tensorflow as tf  
a = tf.constant(1) # 1의 값을 갖는 Tensor a 생성  
b = tf.constant(2) # 2의 값을 갖는 Tensor b 생성
```

# TensorFlow Basic

1과 2를 더하여 3을 출력하는 프로그램을 작성

Output Node까지 이어지는 **Graph**를 그린다

```
import tensorflow as tf
a = tf.constant(1) # 1의 값을 갖는 Tensor a 생성
b = tf.constant(2) # 2의 값을 갖는 Tensor b 생성
c = tf.add(a,b) # a + b의 값을 갖는 Tensor c 생성
```

# TensorFlow Basic

1과 2를 더하여 3을 출력하는 프로그램을 작성

**Session**을 이용하여 **Graph**를 **Run** 시킨다

```
import tensorflow as tf
a = tf.constant(1) # 1의 값을 갖는 Tensor a 생성
b = tf.constant(2) # 2의 값을 갖는 Tensor b 생성

c = tf.add(a,b) # a + b의 값을 갖는 Tensor c 생성

sess = tf.Session() # Session 생성

# Session을 이용하여 구하고자 하는 Tensor c를 run
print (sess.run(c)) # 3
```

Tip. native operation op `+, -, *, /` 는 TensorFlow Op 처럼 사용가능

```
c = tf.add(a,b) <-> c = a + b
c = tf.subtract(a,b) <-> c = a - b
c = tf.multiply(a,b) <-> c = a * b
c = tf.div(a,b) <-> c = a / b
```

# Exploring in Tensor: Tensor name

```
import tensorflow as tf
a = tf.constant(1)
b = tf.constant(2)
c = tf.add(a,b)
sess = tf.Session()

print (a, b, c, sess)
print (sess.run(c)) # 3
```

Tensor("Const:0", shape=(), dtype=int32, Tensor("Const\_1:0", shape=(), dtype=int32), Tensor("Add:0", shape=(), dtype=int32)

3

모든 텐서는 op **name**으로 구분 및 접근되어서, 이후 원하는 텐서를 가져오는 경우 나, 저장(Save)/복원(Restore) 또는 재사용(reuse) 할 때에도 name으로 접근하기 때문에 텐서 name 다루는 것에 익숙해지는 것이 좋습니다

# Placeholder: Session runtime에 동적으로 Tensor의 값을 주입하기

Placeholder: 선언 당시에 값은 비어있고, 형태(shape)와 타입(dtype)만 정의되어 있어 Session runtime에 지정한 값으로 텐서를 채울 수 있음

Feed: Placeholder에 원하는 값을 주입하는 것

```
a = tf.placeholder(dtype=tf.float32, shape=[]) # 1차원 실수형 Placeholder 생성
b = tf.placeholder(dtype=tf.float32, shape=[]) # 1차원 실수형 Placeholder 생성
c = a + b
with tf.Session() as sess:
    feed = {a:1, b:2} # python dictionary
    print (sess.run(c, feed_dict=feed)) # 3

    feed = {a:2, b:4.5}
    print (sess.run(c, feed_dict=feed)) # 6.5
```

## Quiz 0.

1. 3x4 행렬에 대한 Placeholder `a` 와 4x6 행렬에 대한 Placeholder `b` 를 선언한다.
2. 행렬 `a`와 `b`를 곱하여 3x6 행렬 `c`로 이어지는 그래프를 그린다.
3. `numpy.random.randn` 함수로 `a`, `b`에 대한 랜덤 feed를 만들고, `Session`을 이용하여 랜덤값으로 채운 `a`, `b`에 대한 `c`의 값을 출력한다.

Tip.

```
import numpy as np
a = np.random.randn(2,3)
print (a)
```

# Variable: 학습하고자 하는 모델의 Parameter

Variable과 Constant/Placeholder의 차이점: 텐서의 값이 변할 수 있느냐 없느냐의 여부

Parameter `W`, `b` 를 `1.0` 으로 초기화 한 후 linear model의 출력 구하기

```
W = tf.Variable(1.0, dtype=tf.float32)
b = tf.Variable(1.0, dtype=tf.float32)
x = tf.placeholder(dtype=tf.float32, shape=[])

linear_model_output = W * x + b

# Important!!
init_op = tf.global_variables_initializer()
with tf.Session() as sess:
    sess.run(init_op)

    feed = {x:5.0}
    sess.run(linear_model_output, feed_dict=feed) # 6
```

만약 `sess.run` 하는 op의 그래프에 변수(`tf.Variable`)이 하나라도 포함되어 있다면, 반드시 해당 변수를 초기화 `tf.global_variables_initializer()` 를 먼저



# Variable: 학습하고자 하는 모델의 Parameter

Parameter `W`, `b` 를 랜덤 으로 초기화 한 후 linear model의 출력 구하기

```
W = tf.Variable(tf.random_normal(shape=[]), dtype=tf.float32)
b = tf.Variable(tf.random_normal(shape=[]), dtype=tf.float32)
x = tf.placeholder(dtype=tf.float32, shape=[])
```

```
linear_model_output = W * x + b
```

```
# Important!!
```

```
init_op = tf.global_variables_initializer()
```

```
with tf.Session() as sess:
```

```
    sess.run(init_op)
```

```
    feed = {x:5.0}
```

```
    sess.run(linear_model_output, feed_dict=feed) # 6
```

# MNIST using Logistic Regression

Code(<https://github.com/yj-yu/tensorflow-basic>)

# MNIST

Image Classification Dataset

0 ~ 9까지의 손글씨 이미지를 알맞은 label로 분류하는 Task

# Example. MNIST Using Logistic Regression

1. 모델의 입력 및 출력 정의
2. 모델 구성하기(Logistic Regression model)
3. Training

# 모델의 입력 및 출력 정의

Input: 28\*28 이미지 = 784차원 벡터 `model_input = [0, 255, 214, ...]`

각각에 해당하는 정답 `labels = [0.0, 1.0, 0.0, 0.0, ...]`

Output: 이미지가 각 클래스에 속할 확률 예측값을 나타내는 10차원 벡터  
`predictions = [0.12, 0.311, ...]`

하고싶은 것은?

모델의 예측값이 정답 데이터(Label 또는 Ground-truth)와 최대한 비슷해지도록  
모델 Parameter를 학습시키고 싶다 <-> `label` 과 `predictions` 의 오차를 최소화  
하고 싶다

# 모델의 입력 및 출력 정의

## 데이터 준비

```
from tensorflow.examples.tutorials.mnist import input_data
mnist = input_data.read_data_sets("./data", one_hot=True)
```

```
for _ in range(10000):
    batch_images, batch_labels = mnist.train.next_batch(100)
    batch_images_val, batch_labels_val = mnist.validation.next_batch(100)
    print (batch_image.shape) # [100, 784]
    print (batch_labels.shape) # [100, 10]
```

# 모델 구성하기

모델의 입력을 Placeholder로 구성

Batch 단위로 학습할 것이기 때문에 `None`을 이용하여 임의의 batch size를 핸들링할 수 있도록 합니다

```
# define model input: image and ground-truth label
model_inputs = tf.placeholder(dtype=tf.float32, shape=[None, 784])
labels = tf.placeholder(dtype=tf.float32, shape=[None, 10])
```

Logistic Regression Model의 Parameter 정의

```
# define parameters for Logistic Regression model
w = tf.Variable(tf.random_normal(shape=[784, 10]))
b = tf.Variable(tf.random_normal(shape=[10]))
```

# 모델 구성하기

## 그래프 그리기

```
logits = tf.matmul(model_inputs, w) + b
predictions = tf.nn.softmax(logits)

# define cross entropy loss term
loss = tf.losses.softmax_cross_entropy(
    onehot_labels=labels,
    logits=predictions)
```



# 모델 구성하기

Optimizer 정의 -> 모델이 **loss**(predictions 와 labels 사이의 차이)를 **최소화** 하는 방향으로 파라미터 업데이트를 했으면 좋겠다

```
optimizer = tf.train.GradientDescentOptimizer(learning_rate=0.01)  
train_op = optimizer.minimize(loss)
```

# Training

Session을 이용하여

Variable들을 초기화시켜준 후에

각 iteration마다 이미지와 라벨 데이터를 batch단위로 가져오고

가져온 데이터를 이용하여 feed를 구성

train\_op(가져온 데이터에 대한 loss를 최소화 하도록 파라미터 업데이트를 하는 Op)을 실행

```
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    for step in range(10000):
        batch_images, batch_labels = mnist.train.next_batch(100)
        feed = {model_inputs: batch_images, labels: batch_labels}
        _, loss_val = sess.run([train_op, loss], feed_dict=feed)
        print ("step {} | loss : {}".format(step, loss_val))
```

## Minor Tips - tensorflow.flags

TensorFlow에서 FLAGS를 통한 argparsing 기능도 제공하고 있습니다.  
HyperParamter(batch size, learning rate, max\_step 등) 세팅에 유용!

```
from tensorflow import flags  
FLAGS = flags.FLAGS
```

```
flags.DEFINE_integer("batch_size", 128, "number of batch size. default 128.")  
flags.DEFINE_float("learning_rate", 0.01, "initial learning rate.")  
flags.DEFINE_integer("max_steps", 10000, "max steps to train.")
```

```
# train.py  
batch_size = FLAGS.batch_size  
learning_rate = FLAGS.learning_rate  
max_step = FLAGS.max_steps
```

```
$ python train.py --batch_size=256 --learning_rate=0.001 --  
max_steps=100000
```

# Result

```
$ python train.py --batch_size=128 --learning_rate=0.01 --  
max_steps=10000
```

```
step 676 | loss 2.34403467178  
step 677 | loss 2.32255005836  
step 678 | loss 2.39399290085  
step 679 | loss 2.37346792221  
step 680 | loss 2.33814549446  
step 681 | loss 2.38984966278  
step 682 | loss 2.38764429092  
step 683 | loss 2.36936712265  
step 684 | loss 2.33105134964  
step 684 | loss 2.33105134964  
step 685 | loss 2.38727355003  
step 686 | loss 2.38139843941  
step 687 | loss 2.37024593353  
step 688 | loss 2.36529493332  
step 689 | loss 2.38960027695  
step 690 | loss 2.38152623177  
step 691 | loss 2.39559197426  
step 692 | loss 2.37230968475  
step 693 | loss 2.391674757  
step 694 | loss 2.38378882408  
step 695 | loss 2.39267778397
```

```
0 ▶ 1- ..outube-8m/src 2* python
```

# Minor Tips - Tensorboard

학습 진행 상황을 Visualize 하고 싶다면? -> Tensorboard 사용

# Minor Tips - Tensorboard

## scalar summary와 histogram summary

loss, learning rate 등 scalar 값을 가지는 텐서들은 scalar summary로, parameter 등 n차원 텐서들은 histogram summary로 선언한다

```
tf.summary.scalar("loss", loss)
tf.summary.histogram("W", w)
tf.summary.histogram("b", b)
```

merge\_all() 로 summary 모으기

```
merge_op = tf.summary.merge_all()
```

# Minor Tips - Tensorboard

이 후, `tf.summary.FileWriter` 객체를 선언하고, Session으로 `merge_op`을 실행하여 Summary를 얻고, `FileWriter`에 추가

```
summary_writer = tf.summary.FileWriter("./logs", sess.graph)
for step in range(10000):
    # some training code...
    sess.run(train_op, feed=...)
    if step % 10 == 0:
        # session으로 merge_op을 실행시켜 summary를 얻고
        summary = sess.run(merge_op, feed_dict=feed)

        # summary_writer 에 얻은 summary값을 추가
        summary_writer.add_summary(summary, step)
```

# Minor Tips - Tensorboard

```
$ tensorboard --logdir="./logs" --port=9000
```

 입력

```
& localhost:9000
```

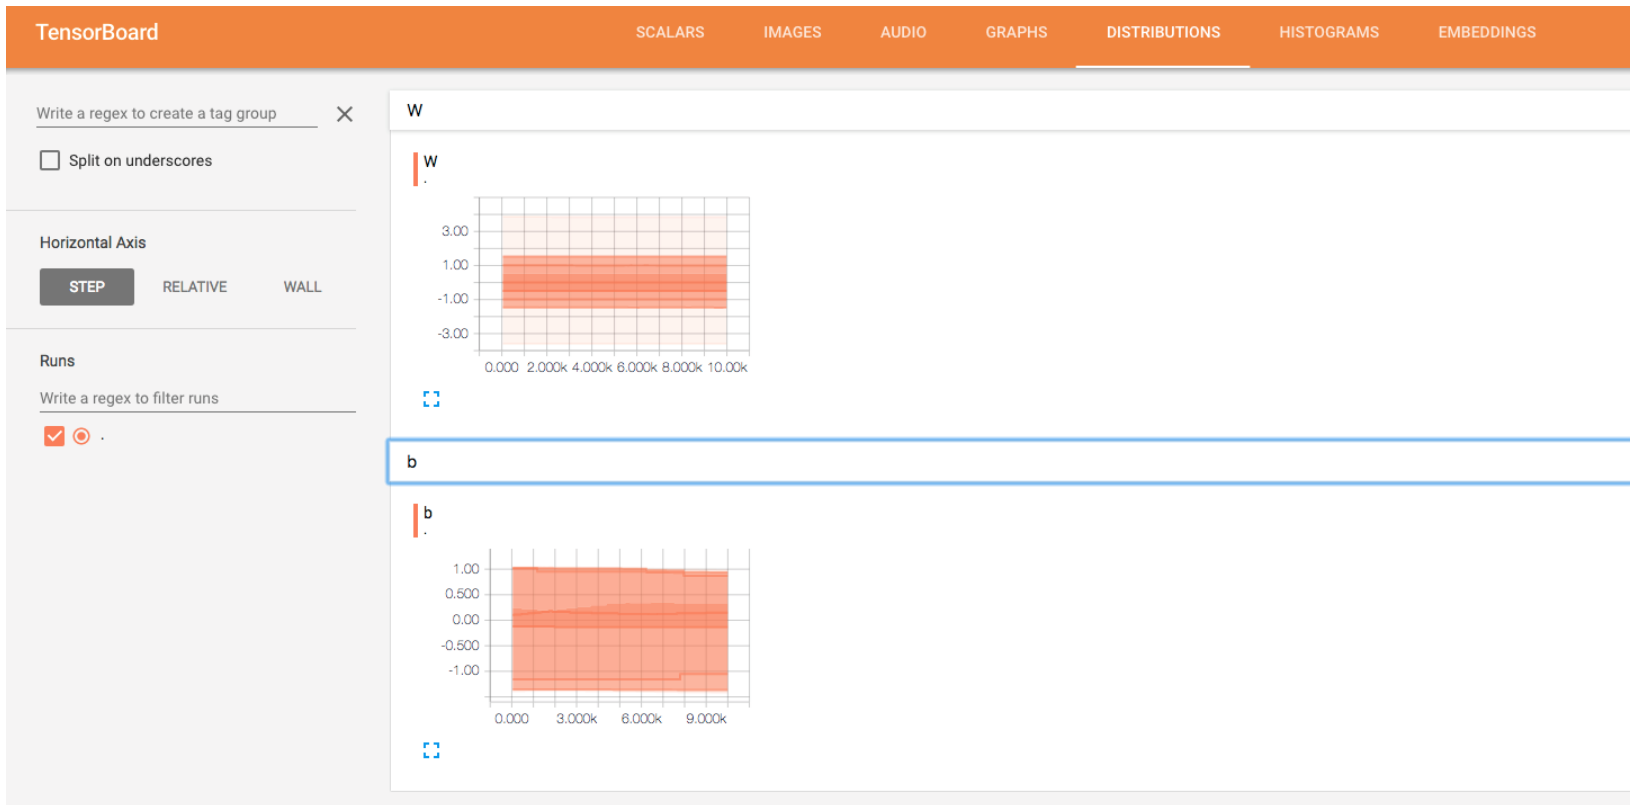
 접속

**scalar summary**



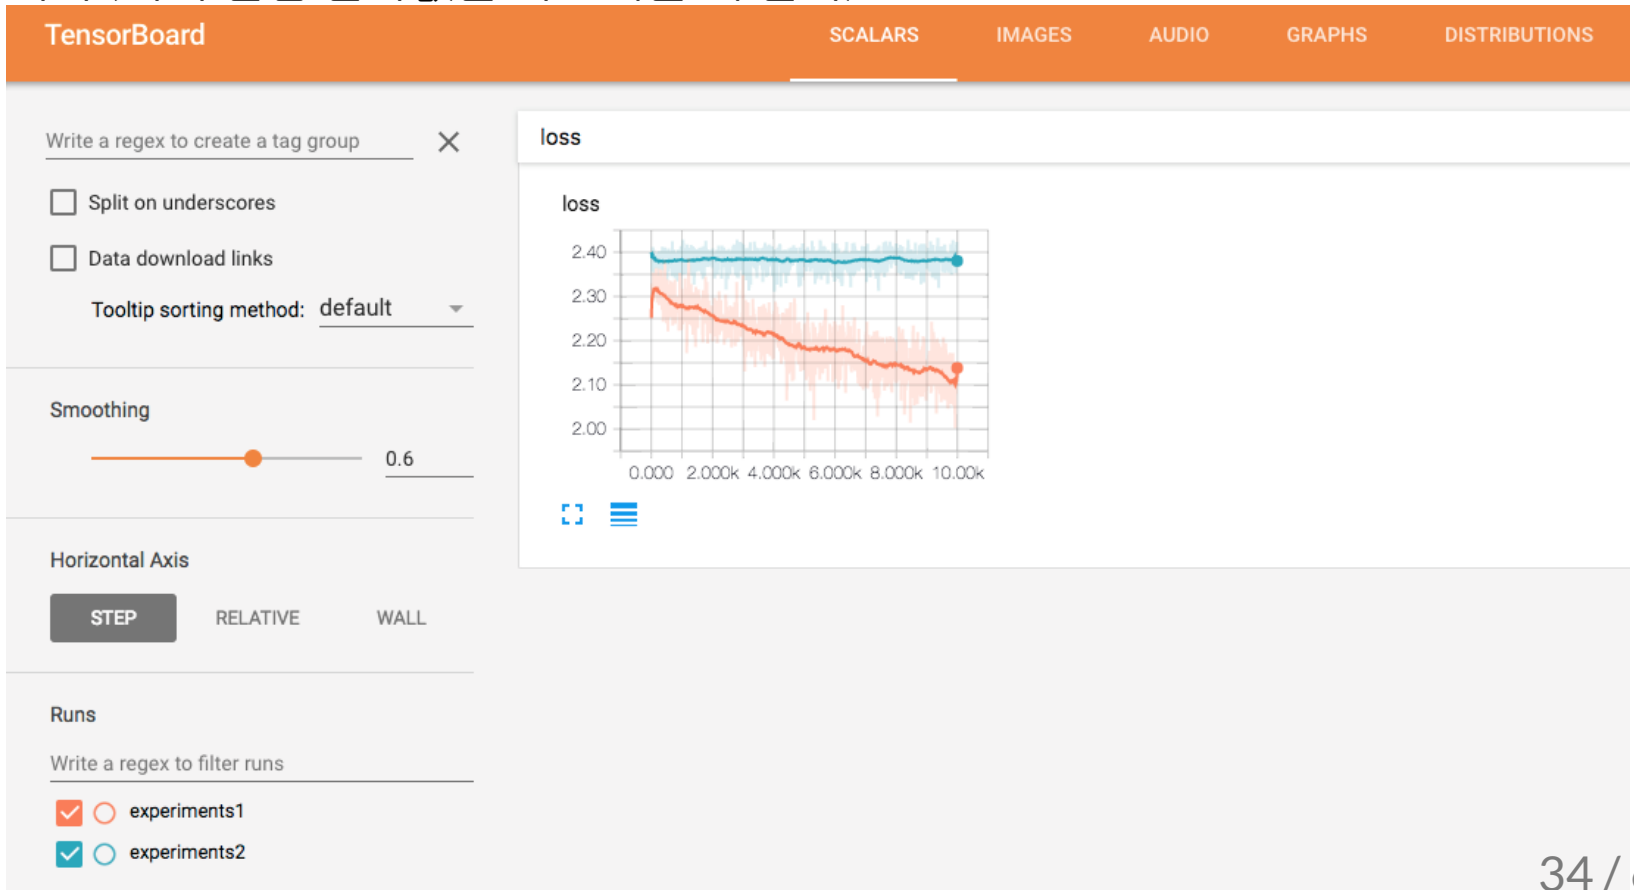
# Minor Tips - Tensorboard

## histogram summary



# Minor Tips - Tensorboard

summary 폴더 여러 개를 두고 서로 다른 실험 결과를 실시간으로 비교할 수도 있습니다 (여러 실험 결과값을 비교해볼 때 편리)

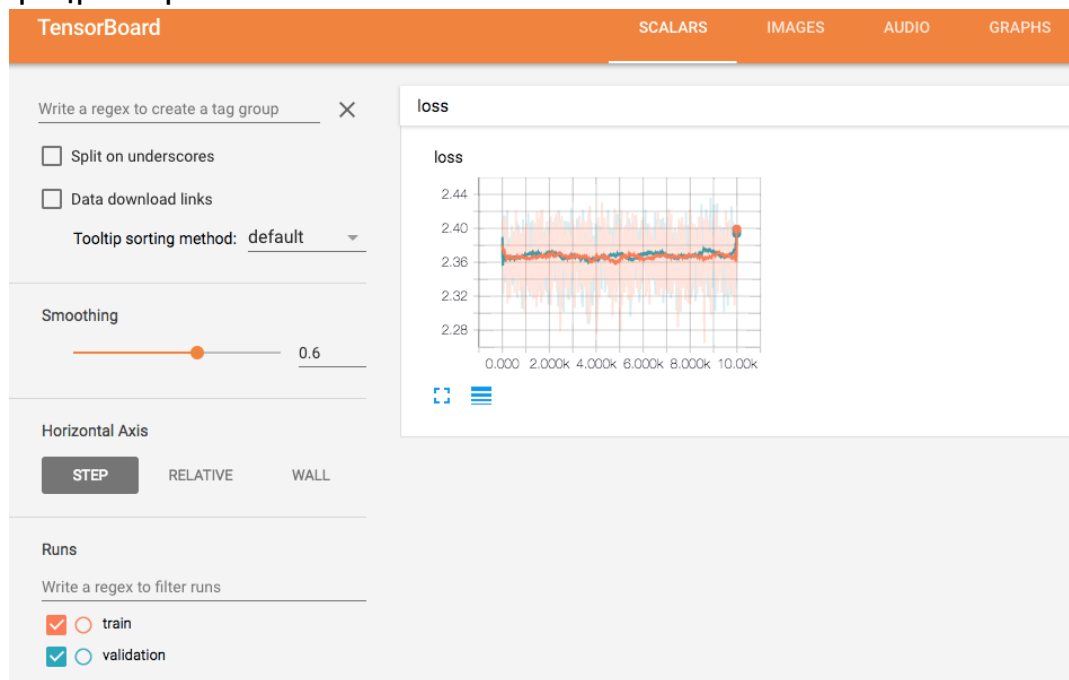


# Quiz 1.

`tf.argmax` `tf.equal` `tf.cast` `tf.reduce_mean` 을 사용하여 Accuracy Tensor 를 정의하고, 이를 Tensorboard에 나타내기

## Quiz 2.

모델을 트레이닝 할 때, `tf.summary.FileWriter` 를 train, validation 용으로 각각 1개씩 만들어서 Tensorboard로 Training/Validation performance 를 함께 모니터링 할 수 있도록 해보기



# Variable Saving & Restoring

# Variable Saving, Restoring

학습은 어찌저찌 잘 했는데...

우리의 목적은 모델 학습 그 자체가 아님!

학습한 모델을 이용하여 새로운 입력  $X$ 에 대하여 그에 알맞은 출력을 내는 것이 원래 목표였습니다.

그렇다면, Training Phase에서 모델이 학습한 Parameter들의 값을 디스크에 저장해놓고, 나중에 불러올 수 있어야겠다.

`tf.train.Saver` 모듈을 통해서 이와 같은 기능을 수행할 수 있습니다.

# Variable name

시작하기 전에... 처음에 배웠던 Tensor name에 대해서 자세히 알아야 합니다.

모든 텐서는 선언하는 시점에 이름이 자동으로 부여되며, 중복되지 않습니다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10]))
b = tf.Variable(tf.zeros(shape=[10]))
print (a.name)
print (b.name)
```

Variable:0

Variable\_1:0

# Variable name

`name` 을 통해서 이름을 명시적으로 지정할 수도 있지만, 같은 이름으로 지정된 경우 중복을 피하기 위해 자동으로 인덱스가 붙습니다.

```
c = tf.Variable(tf.ones(shape=[10]), name="my_variable")
d = tf.Variable(tf.zeros(shape=[]), name="my_variable")

print (c.name)
print (d.name)
```

my\_variable:0

my\_variable\_1:0



# Variable name

`name` 을 통해서 이름을 명시적으로 지정할 수도 있지만, 같은 이름으로 지정된 경우 중복을 피하기 위해 자동으로 인덱스가 붙습니다.

```
c = tf.Variable(tf.ones(shape=[10]), name="my_variable")
d = tf.Variable(tf.zeros(shape=[]), name="my_variable")

print (c.name)
print (d.name)
```

한줄 요약: 모든 텐서에는 중복되지 않게 이름이 부여된다.

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt")
```

변수 a와 b를 선언합니다. 이름을 따로 지정해주지 않았으므로 `Variable_0:0` 과 같이 자동으로 지정됩니다.

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt")
```

Saver 객체를 생성합니다. Saver 객체 안에 아무런 파라미터가 없다면, 기본적으로 Saver 객체는 `{key="Variable name", value=Variable Tensor}` 쌍의 dictionary를 내부적으로 가지게 됩니다.

즉, 이 경우에 Saver 객체가 가지고 있는 dictionary는 `{"Variable_0:0":a, "Variable_1:0":b}` 가 됩니다.

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt")
```

`initializer` 를 실행시키면 Variable `a` `b`에 값이 할당됩니다.

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt")
```

현재 Saver 객체가 가지고 있는 dictionary 정보를 디스크의 `"./logs/model.ckpt"` 이름으로 저장(save)합니다. 저장된 파일을 **checkpoint** 라고 부릅니다.

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt")
```

다음과 같이 저장되어 있는 것을 확인할 수 있습니다.

```
./
├── train.py
└── logs
    ├── checkpoint
    ├── model.ckpt.data-00000-of-00001
    ├── model.ckpt.index
    └── model.ckpt.meta
```

# Variable Saving, Restoring

그럼 이제, `tf.train.Saver` 객체를 이용해 변수 저장을 해봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    # some training code...
    save_path = saver.save(sess, "./logs/model.ckpt", global_step=1000)
```

`global_step` 인자를 통해서 현재 트레이닝 i번째 스텝의 파라미터 값을 가지고 있는 체크포인트임을 명시할 수 있습니다.

```
./
├── train.py
└── logs
    ├── checkpoint
    ├── model.ckpt-1000.data-000000-of-00001
    ├── model.ckpt-1000.index
    └── model.ckpt-1000.meta
```

# Variable Saving, Restoring

checkpoint를 저장했으니, 저장한 checkpoint를 불러와 기록되어있는 파라미터 값으로 변수 값을 채워봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    # some training code...
    saver.restore(sess, "./logs/model.ckpt-1000")
    # sess.run(tf.global_variables_initializer())
```

변수 `a`, `b`를 생성하고 Saver 객체를 생성합니다.

Saver 객체가 인자 없이 선언되었으니, 생성된 모든 변수들에 대한 dictionary를 가지고 있습니다: `{"Variable_0:0":a, "Variable_1:0":b}`



# Variable Saving, Restoring

checkpoint를 저장했으니, 저장한 checkpoint를 불러와 기록되어있는 파라미터 값으로 변수 값을 채워봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    # some training code...
    saver.restore(sess, "./logs/model.ckpt-1000")
    # sess.run(tf.global_variables_initializer())
```

checkpoint 파일의 이름을 인자로 넣어 저장된 파라미터 값을 불러옵니다.

이 시점에서, saver 객체가 가지고 있는 dictionary의 key값을 checkpoint파일에  
서 찾고, 매칭되는 checkpoint 파일의 key값이 존재한다면, 해당 value 텐서의 값을  
saver 객체가 가지고 있는 dictionary의 value에 할당합니다.

# Variable Saving, Restoring

checkpoint를 저장했으니, 저장한 checkpoint를 불러와 기록되어있는 파라미터 값으로 변수 값을 채워봅시다.

```
import tensorflow as tf
a = tf.Variable(tf.random_normal(shape=[10])) #a.name="Variable_0:0"
b = tf.Variable(tf.random_normal(shape=[5])) # b.name="Variable_1:0"
saver = tf.train.Saver()
with tf.Session() as sess:
    # some training code...
    saver.restore(sess, "./logs/model.ckpt-1000")
    # sess.run(tf.global_variables_initializer())
```

variable initializer를 restoring 이후에 run 하지 않는다는 사실에 주의해야 합니다.

만약 restoring 이후에 initializer run을 하게 되면, 불러온 파라미터 값이 전부 지워지고 원래 변수의 initializer로 초기화됩니다.

## Quiz 3.

1. MNIST에 모델을 트레이닝하고, checkpoint파일을 저장합니다.
2. `eval.py` 파일을 만들고, 그래프를 그린 후 저장한 checkpoint 파일을 restore 합니다.
3. 전체 Validation data에 대해서 불러온 파라미터 값을 가지는 모델을 Fully Evaluation하는(전체 Validation data 대한 Accuracy) 코드를 작성해 봅시다.

Tip. Validation data는 5000개 Image/Label pair이고, `batch_size=100` 으로 50 iteration을 돌려서 Accuracy를 평균내면 됩니다.

# Deep Neural Network using TensorFlow

# 시작하기 전에...

## 데이터 준비

```
mnist = input_data.read_data_sets( # data loading...)
```

## 그래프 그리기

```
x = tf.placeholder(dtype=tf.float32, shape=[None, 784])  
# ...  
logits = tf.matmul() # ...  
# ...  
predictions = # ...
```

- 모델 부분만 빼면 `part1/train.py` 코드와 대부분 중복된다
- 모델 코드와 트레이닝 코드를 분리하면 각 컴포넌트를 수정하기 매우 편리해짐
- 코드를 `models.py` 와 `train.py` 로 분리해보자!

# Code structure

```
./code-part2  
├── train.py  
└── models.py
```

- `train.py` : 모델 코드를 제외하고 Loss 계산, Optimizer 정의 및 학습 코드를 포함한다
- `models.py` : class 형태의 모델 코드를 포함한다.

# DNN

Input 텐서들을 입력으로 받아, predictions 를 출력으로 하는 구조의 모델

```
# models.py
class DNN(object):
    def create_model(self, model_inputs):
        # model architectures here!
        # ...

        return predictions
```

# DNN

## 필요한 파라미터 선언

```
# models.py  
def create_model(model_inputs):  
    initializer = tf.random_normal  
    w1 = tf.Variable(initializer(shape=[784, 128]))  
    b1 = tf.Variable(initializer(shape=[128]))  
  
    w2 = tf.Variable(initializer(shape=[128, 10]))  
    b2 = tf.Variable(initializer(shape=[10]))
```



# DNN

## 그래프 그리기

```
# models.py
h1 = tf.nn.relu(tf.matmul(model_inputs, w1) + b1) # 1st hidden layer

logits = tf.matmul(h1, w2) + b2
predictions = tf.nn.softmax(logits)

return predictions
```

`models.py` 안에 있는 모델 class가 input tensor를 argument를 받아 그에 대한 output(`predictions`)을 리턴하도록 합니다

# DNN

Trainer - data reader, 모델 불러오기, train\_op 정의, Session run 등

```
# train.py
mnist = input_data.read_data_sets("./data", one_hot=True)

# define model input: image and ground-truth label
model_inputs = tf.placeholder(dtype=tf.float32, shape=[None, 784])
labels = tf.placeholder(dtype=tf.float32, shape=[None, 10])
```

# DNN

모델 불러오기 `getattr` 함수 사용

```
# train.py
import models
models = getattr(models, "DNN", None)
predictions = models.create_model(model_inputs)
```

모델이 여러개인 경우에, 다음과 같이 `tf.flags` 모듈을 이용하여 `argparse`로 사용할 모델을 선택하면 편리합니다. (대신 코드의 일관성을 위해 반드시 **모든 모델의 입출력 포맷이 같아야 함**)

```
# train.py
import models
models = getattr(models, flags.model, None)
predictions = models.create_model(model_inputs)
```

```
$ python train.py --model=DNN
```

```
$ python train.py --model=LogisticRegression
```

# DNN

## loss & train op 정의

```
# train.py  
# define cross entropy loss term  
loss = tf.losses.softmax_cross_entropy(  
    onehot_labels=labels,  
    logits=predictions)  
  
# train.py 안에서 정의되는 텐서들에 대하여 summary 생성  
tf.summary.scalar("loss", loss)  
merge_op = tf.summary.merge_all()  
  
optimizer = tf.train.GradientDescentOptimizer(learning_rate=0.0001)  
train_op = optimizer.minimize(loss)
```

# DNN

## Session으로 Training 실행

```
with tf.Session() as sess:
    summary_writer_train = tf.summary.FileWriter("./logs/train", sess.graph)

    sess.run(tf.global_variables_initializer())
    for step in range(10000):
        batch_images, batch_labels = mnist.train.next_batch(100)
        feed = {model_inputs: batch_images, labels: batch_labels}
        _, loss_val = sess.run([train_op, loss], feed_dict=feed)
        print ("step {} | loss {}".format(step, loss_val))

    if step % 10 == 0:
        summary_train = sess.run(merge_op, feed_dict=feed)
        summary_writer_train.add_summary(summary_train, step)
```

DNN

Hmm...

# DNN

더 잘할 수 있을까?

모델의 구조를 이것저것 바꿔봅시다

- Hidden Layer 의 개수
- 각 Hidden Layer 의 차원(Dimension)
- Learning rate
- Optimizer 종류 (`tf.train.GradientDescentOptimizer`,  
`tf.train.AdamOptimizer`, ...)
- Batch size

등등...

Do it!

# Thank You!

**Special Thanks to:** Seil Na, Jongwook Choi, Byungchang Kim

Slideshow created using [remark](#).